

Projet de fin de module : Programmation Python Avancée
Réalisation d'un Chatbot basé sur les données Scopus
(A rendre avant 20/07/2025)

1. Introduction

Scopus (<https://www.scopus.com/home.uri>) est une grande base de données bibliographique contenant des résumés et des citations pour des articles de revues académiques. Il est géré par Elsevier, un éditeur majeur de revues scientifiques et de littérature universitaire. Scopus couvre une vaste gamme de disciplines scientifiques, techniques, médicales et sociales, offrant des outils pour la recherche et l'analyse des publications scientifiques.

2. Objectif du projet

L'objectif de ce projet est de développer un chatbot intelligent capable d'interagir avec l'utilisateur en langage naturel afin de répondre à des questions portant sur des publications scientifiques issues de Scopus. Le chatbot exploitera des techniques de NLP et d'indexation sémantique pour offrir des réponses pertinentes, synthétiques et contextualisées.

3. Besoins fonctionnels

Le système devra permettre :

- L'extraction et la gestion automatisée de données bibliographiques depuis Scopus.
- Une recherche intelligente basée sur la compréhension des intentions (intent) et entités dans les requêtes utilisateurs.
- La génération de réponses personnalisées, sous forme de textes, résumés ou visualisations.
- Une interface utilisateur fluide, accessible et facile à prendre en main.

4. Étapes de réalisation

a. Extraction des données Scopus

- Méthodes : Extraction automatique via l'API Scopus (requiert une clé API Elsevier).
- Données ciblées : Titre, résumé, auteurs, affiliation, année, DOI, mots-clés.

b. Nettoyage et stockage

- Nettoyage des données avec Pandas :
 - Suppression des doublons, normalisation des auteurs et affiliations.
 - Traitement des caractères spéciaux et valeurs manquantes.
- Stockage local : Structuration en tables relationnelles (auteurs, articles, affiliations...).

- c. Indexation sémantique des résumés
 - Utilisation de Sentence Transformers (BERT, MiniLM, etc.) pour vectoriser les résumés.
 - Création d'un index vectoriel via FAISS ou ChromaDB pour recherche sémantique rapide.
 - L'index permet de retrouver les articles les plus proches d'une requête textuelle.
- d. Interface utilisateur simple et fluide
 - Web app légère avec Streamlit, Gradio ou Flask.
 - Fonctionnalités :
 - Zone de saisie des questions.
 - Affichage clair des résultats.
 - Option de filtrage par année, auteur, etc.
 - Visualisations interactives (Plotly, Altair...).

5. Livrables attendus

- Script d'extraction et de traitement des données Scopus.
- Base de données structurée avec contenu nettoyé.
- Moteur de recherche sémantique.
- Application web fonctionnelle avec chatbot.
- Documentation technique + guide utilisateur.

Indications

Voici quelques indications qui peuvent vous aider dans la réalisation du projet :

Pour l'étape b, vous pouvez considérer les tables suivantes :

Données d'article

- Titre (title)
- Résumé (abstract)
- Année de publication (coverDate)
- Revue (prism:publicationName)
- DOI (prism:doi)
- Identifiant Scopus (dc:identifier)
- Mots-clés (authkeywords)
- Domaine de recherche (subject-area)

Données d'auteur

- Nom complet (preferred-name)
- Scopus Author ID (@auid)
- ORCID (si disponible)
- Affiliation principale (affiliation-current)
- Affiliations multiples peuvent ne pas être toujours complètes.

Données d’affiliation

- Nom de l’institution
- Pays
- Identifiant Affiliation Scopus

Relations auteur–article / affiliation–auteur

- Lien entre article et auteurs (author dans abstract).
- Affiliation de l’auteur, pour chaque article.

Pour l’étape c :

Transformer les résumés des articles en vecteurs numériques de manière à pouvoir faire une recherche sémantique (par similarité de sens) à l’aide d’un moteur comme FAISS ou ChromaDB, en utilisant la bibliothèque : sentence-transformers.